

Pruebas de NORMALIDAD: ANDERSON-DARLING, RYAN-JOINER, SHAPIRO-WILK Y KOLMOGÓROV-SMIRNOV ANDERSONDARLING, RYAN-JOINER, SHAPIRO-WILK Y KOLMOGÓROV-SMIRNOV

Mg. RMMB Fisarth¹

¹Departamento de matemática
Universidad Nacional de San Cristobal de Huamanga & ESFA FGPA

Sesión ***prueba de hipótesis no paramétrico de normalidad*** (Estadística
inferencial), 2024

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Prueba de ANDERSON-DARLING, RYAN-JOINER, SHAPIRO-WILK Y KOLMOGOROV-SMIRNOV

- Son pruebas no paramétricas (de normalidad)
- Trabaja con un solo grupo de variables *cuantitativas*
- *Son pruebas decisión, si se usará pruebas paramétricas o no paramétricas*

Prueba de ANDERSON-DARLING, RYAN-JOINER, SHAPIRO-WILK Y KOLMOGOROV-SMIRNOV

- Son pruebas no paramétricas (de normalidad)
- Trabaja con un solo grupo de variables *cuantitativas*
- ***Son pruebas decisión, si se usará pruebas paramétricas o no paramétricas***

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Pruebas no paramétricas

- χ^2
 - χ^2 bondad de ajuste.
 - χ^2 de independencia
 - χ^2 de homogeneidad
- McNemar
- Q de Cochran
- U Mann Withney
- Kruskal Wallis
- Rangos de Wilcoxon
- Friedman

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Prueba ANDERSON-DARLING

En estadística, la prueba de Anderson-Darling es una prueba no paramétrica sobre si los datos de una muestra provienen de una distribución específica. La fórmula para el estadístico A determina si los datos $\{Y_1 < \dots < Y_n\}$ (**observe que los datos se deben ordenar**) vienen de una distribución con función acumulativa F , $AD = -n - S$ donde $S = \sum_{i=1}^n \frac{2i-1}{n} [\ln(F(x_i)) + \ln(1 - F(x_{n+1-i}))]$

$$AD^* = AD \left(1 + \frac{0.75}{n} + \frac{2.25}{n^2} \right)$$

- Si $AD^* \geq 0.6$, $p = \exp(1.2937 - 5.709(AD^*) + 0.0186(AD^*)^2)$
- Si $0.34 < AD^* < 0.6$, $p = \exp(0.9177 - 4.279(AD^*) - 1.38(AD^*)^2)$
- Si $0.2 < AD^* < 0.34$, $p = 1 - \exp(-8.318 + 42.796(AD^*) - 59.938(AD^*)^2)$
- Si $AD^* \leq 0.2$, $p = 1 - \exp(-13.436 + 101.14(AD^*) - 223.73(AD^*)^2)$

ANDERSON-DARLING

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($20 \leq n \leq 100$)

$$AD = -n - S$$

donde $S = \sum_{i=1}^n \frac{2i-1}{n} [\ln(F(Y_i)) + \ln(1 - F(Y_{n+1-i}))]$.

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $AD < AD_{\alpha}$, $AD_{0.05} = 0.751$ tabla Anderson-Darling (http://catarina.udlap.mx/u_dl_a/tales/documentos/lat/ramirez_r_pa/apendiceD.pdf)
Se acepta h_0 .

ANDERSON-DARLING

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($20 \leq n \leq 100$)

$$AD = -n - S$$

donde $S = \sum_{i=1}^n \frac{2i-1}{n} [\ln(F(Y_i)) + \ln(1 - F(Y_{n+1-i}))]$.

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $AD < AD_{\alpha}$, $AD_{0.05} = 0.751$ tabla Anderson-Darling (http://catarina.udlap.mx/u_dl_a/tales/documentos/lat/ramirez_r_pa/apendiceD.pdf)
Se acepta h_0 .

Ejemplo ANDERSON-DARLING

$S = \sum_{i=1}^n S_i$, $S_i = \frac{2i-1}{n} [\ln(F(x_i)) + \ln(1 - F(x_{n+1-i}))]$; A_O : Altura ordenada creciente, A_{OI} : Altura ordenada decreciente, $x_i = \frac{A_O - \bar{x}}{s}$ y $x_{n-i+1} = \frac{A_{OI} - \bar{x}}{s}$ (estandar)

A_O	A_{OI}	i	x_i	x_{n-i+1}	$\underbrace{F(x_i)}_{\alpha}$	$\underbrace{F(x_{n-i+1})}_{\beta}$	$\ln(\alpha)$	$\ln(1 - \beta)$	S_i
3334	3838	1	-1.43	0.95	0.08	0.83	0.83	-1.76	-0.87
3554	3837	2	-0.39	0.94	0.35	0.83	0.83	-1.75	-1.69
3625	3625	3	-0.06	-0.06	0.48	0.48	0.48	-0.65	-1.39
3837	3554	4	0.94	-0.39	0.83	0.35	0.35	-0.43	-0.86
3838	3334	5	0.95	-1.43	0.83	0.08	0.08	-0.08	-0.48
$\bar{x}$	3637.6				$AD = -n - S$				0.2879
s	211.68				$AD^* = AD \left(1 + \frac{0.75}{n} + \frac{2.25}{n^2} \right)$				0.3571

$AD = 0.2879 < AD_{\alpha} = AD_{0.05} = 0.751$. ($0.34 < AD^* < 0.6$,

$p = \exp(0.9177 - 4.279(0.3571) - 1.38(0.3571)^2) = 0.456 > 0.05$) Se acepta H_0

Ejemplo ANDERSON-DARLING

$S = \sum_{i=1}^n S_i$, $S_i = \frac{2i-1}{n} [\ln(F(x_i)) + \ln(1 - F(x_{n+1-i}))]$; A_O : Altura ordenada creciente, A_{OI} : Altura ordenada decreciente, $x_i = \frac{A_O - \bar{x}}{s}$ y $x_{n-i+1} = \frac{A_{OI} - \bar{x}}{s}$ (estandar)

A_O	A_{OI}	i	x_i	x_{n-i+1}	$\underbrace{F(x_i)}_{\alpha}$	$\underbrace{F(x_{n-i+1})}_{\beta}$	$\ln(\alpha)$	$\ln(1 - \beta)$	S_i
3334	3838	1	-1.43	0.95	0.08	0.83	0.83	-1.76	-0.87
3554	3837	2	-0.39	0.94	0.35	0.83	0.83	-1.75	-1.69
3625	3625	3	-0.06	-0.06	0.48	0.48	0.48	-0.65	-1.39
3837	3554	4	0.94	-0.39	0.83	0.35	0.35	-0.43	-0.86
3838	3334	5	0.95	-1.43	0.83	0.08	0.08	-0.08	-0.48
$\bar{x}$	3637.6				$AD = -n - S$				0.2879
s	211.68				$AD^* = AD \left(1 + \frac{0.75}{n} + \frac{2.25}{n^2} \right)$				0.3571

$AD = 0.2879 < AD_{\alpha} = AD_{0.05} = 0.751$. ($0.34 < AD^* < 0.6$,

$p = \exp(0.9177 - 4.279(0.3571) - 1.38(0.3571)^2) = 0.456 > 0.05$) Se acepta H_0

Ejemplo ANDERSON-DARLING

$S = \sum_{i=1}^n S_i$, $S_i = \frac{2i-1}{n} [\ln(F(x_i)) + \ln(1 - F(x_{n+1-i}))]$; A_O : Altura ordenada creciente, A_{OI} : Altura ordenada decreciente, $x_i = \frac{A_O - \bar{x}}{s}$ y $x_{n-i+1} = \frac{A_{OI} - \bar{x}}{s}$ (estandar)

A_O	A_{OI}	i	x_i	x_{n-i+1}	$\underbrace{F(x_i)}_{\alpha}$	$\underbrace{F(x_{n-i+1})}_{\beta}$	$\ln(\alpha)$	$\ln(1 - \beta)$	S_i
3334	3838	1	-1.43	0.95	0.08	0.83	0.83	-1.76	-0.87
3554	3837	2	-0.39	0.94	0.35	0.83	0.83	-1.75	-1.69
3625	3625	3	-0.06	-0.06	0.48	0.48	0.48	-0.65	-1.39
3837	3554	4	0.94	-0.39	0.83	0.35	0.35	-0.43	-0.86
3838	3334	5	0.95	-1.43	0.83	0.08	0.08	-0.08	-0.48
$\bar{x}$	3637.6				$AD = -n - S$				0.2879
s	211.68				$AD^* = AD \left(1 + \frac{0.75}{n} + \frac{2.25}{n^2} \right)$				0.3571

$AD = 0.2879 < AD_{\alpha} = AD_{0.05} = 0.751$. ($0.34 < AD^* < 0.6$,

$p = \exp(0.9177 - 4.279(0.3571) - 1.38(0.3571)^2) = 0.456 > 0.05$) Se acepta h_0

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

RYAN-JOINER

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($30 \leq n$)

$$R_p = \frac{\sum (x_i - \bar{x}) b_i}{\sqrt{s^2 (n-1) \sum b_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{s^2 (n-1) \sum z_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{\sum (x_i - \bar{x})^2 \sum z_i^2}}$$

con la x_i observaciones ordenadas de manera creciente y $b_i = \frac{i-0.375}{n+0.25}$,
 $z_i = \text{NORM.S.INV}(b_i)$.

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $R_p > R_c$, (se acepta h_0).

RYAN-JOINER

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($30 \leq n$)

$$R_p = \frac{\sum (x_i - \bar{x}) b_i}{\sqrt{s^2 (n-1) \sum b_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{s^2 (n-1) \sum z_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{\sum (x_i - \bar{x})^2 \sum z_i^2}}$$

con la x_i observaciones ordenadas de manera creciente y $b_i = \frac{i-0.375}{n+0.25}$,
 $z_i = \text{NORM.S.INV}(b_i)$.

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $R_p > R_c$, (se acepta h_0).

$$R_p = \frac{\sum (x_i - \bar{x}) b_i}{\sqrt{s^2(n-1) \sum b_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{s^2(n-1) \sum z_i^2}}, \quad n = 5 \text{ y } b_i = \frac{i-0.375}{n+0.25}$$

Ya que $\alpha = 0.05$ se tiene

$$R_p = \frac{\sum (x_i - \bar{x}) b_i}{\sqrt{s^2(n-1) \sum b_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{s^2(n-1) \sum z_i^2}}, \quad n = 5 \text{ y } b_i = \frac{i-0.375}{n+0.25}$$

$$R_p = \frac{\sum (x_i - \bar{x}) b_i}{\sqrt{s^2(n-1) \sum b_i^2}} \sim \frac{\sum x_i z_i}{\sqrt{s^2(n-1) \sum z_i^2}}, \quad n = 5 \text{ y } b_i = \frac{i-0.375}{n+0.25}$$

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Prueba SHAPIRO-WILK

En estadística, la prueba de Shapiro-Wilk se usa para contrastar la normalidad de un conjunto de datos. Se plantea como hipótesis nula que una muestra $x_1, \dots, x_n$ proviene de una población normalmente distribuida. Fue publicado en 1965 por Samuel Shapiro y Martin Wilk. El estadístico de la prueba es:

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde

$x_{(i)}$ (con el subíndice i entre paréntesis) es el número que ocupa la i -ésima posición en la muestra (**con la muestra ordenada de menor a mayor**); $\bar{x} = \frac{x_1 + \dots + x_n}{n}$ es la media muestral; las variables a_i donde a_i en tabla de Shapiro-Wilk
(<https://real-statistics.com/statistics-tables/shapiro-wilk-table/>).

SHAPIRO-WILK

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($n \leq 50$). $x_{(i)}$ **ordenados de manera creciente.**

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde a_i se hallan en la tabla de Shapiro-Wilk
(<https://real-statistics.com/statistics-tables/shapiro-wilk-table/>).

- Nivel de significancia $\alpha = 0.05$ $W_{5,0.05} = 0.762$ se hallan en la tabla de Shapiro-Wilk (<https://real-statistics.com/statistics-tables/shapiro-wilk-table/>).
- Regla de decisión. Si $W > W_{n,\alpha}$, (se acepta h_0).

SHAPIRO-WILK

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($n \leq 50$). $x_{(i)}$ **ordenados de manera creciente.**

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde a_i se hallan en la tabla de Shapiro-Wilk
(<https://real-statistics.com/statistics-tables/shapiro-wilk-table/>).

- Nivel de significancia $\alpha = 0.05$ $W_{5,0.05} = 0.762$ se hallan en la tabla de Shapiro-Wilk (<https://real-statistics.com/statistics-tables/shapiro-wilk-table/>).
- Regla de decisión. Si $W > W_{n,\alpha}$, (se acepta h_0).

Ejemplo SHAPIRO-WILK

$x_{(i)}$	a_i	$a_i x_{(i)}$	$(x_i - \bar{x})^2$
3334	0.6646	2215.7764	92172.96
3554	0.2413	857.5802	6988.96
3625	0	0	158.76
3837	-0.6646	-2550.0702	39760.36
3838	-0.2413	-926.1094	40160.16
	Σ	-402.823	179241.2
$\bar{x}$	3637.6		
$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)} \right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$	0.905		

Ya que $W = 0.905 > 0.762 = W_{n,\alpha} = W_{5,0.05}$ (Tabla W) entonces se acepta h_0

Índice

1 Motivación

- El problema básico que estudiamos
- Trabajo previo

2 Nuestros resultados/Contribución

- Prueba ANDERSON-DARLING
- Prueba RYAN-JOINER
- Prueba SHAPIRO-WILK
- Prueba KOLMOGÓROV-SMIRNOV

Prueba KOLMOGÓROV-SMIRNOV

Si $D_{n,\alpha}$ es el valor crítico de la tabla (One-Sample Kolmogorov-Smirnov Table:<https://real-statistics.com/statistics-tables/kolmogorov-smirnov-table/>), entonces $P(D_n \leq D_{n,\alpha}) = 1 - \alpha$. D_n Se puede utilizar para probar la hipótesis de que una muestra aleatoria proviene de una población con una función de distribución específica. $F(x)$. Si

$$\max |F(x) - S_n(x)| \leq D_{n,\alpha}$$

entonces la muestra se ajusta muy bien con $F(x)$

KOLMOGÓROV-SMIRNOV

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($50 \leq n$). x_i ordenados de manera creciente

$$D_n = \max |F(x_i) - S_n(x_i)| \leq D_{n,\alpha}$$

donde $F(x_i)$, es la probabilidad acumulada $S_n(x_i)$ acumulada de las frecuencias absolutas, además el valor crítico $D_{n,\alpha}$ en la tabla de Kolmogorov Smirnov (<https://real-statistics.com/statistics-tables/kolmogorov-smirnov-table/>).

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $D_n < D_{n,\alpha}$, (se acepta h_0).

KOLMOGÓROV-SMIRNOV

- Hipótesis. Nula (h_0 : Los datos provienen de una población normal) y alterna (h_1 : $\neg h_0$)
- Estadística ($50 \leq n$). x_i ordenados de manera creciente

$$D_n = \max |F(x_i) - S_n(x_i)| \leq D_{n,\alpha}$$

donde $F(x_i)$, es la probabilidad acumulada $S_n(x_i)$ acumulada de las frecuencias absolutas, además el valor crítico $D_{n,\alpha}$ en la tabla de Kolmogorov Smirnov (<https://real-statistics.com/statistics-tables/kolmogorov-smirnov-table/>).

- Nivel de significancia $\alpha = 0.05$.
- Regla de decisión. Si $D_n < D_{n,\alpha}$, (se acepta h_0).

Ejemplo KOLMOGÓROV-SMIRNOV

x_i	f_i	F_i	$S_n(x_i) = H_i$	$z_i = \frac{(x_i - \bar{x})}{s}$	$F(x_i) = P(z \leq z_i)$	$ F(x_i) - S_n(x_i) $
3334	1.00	1.00	0.20	-1.43	0.08	0.12
3554	1.00	2.00	0.40	-0.39	0.35	0.05
3625	1.00	3.00	0.60	-0.06	0.48	0.12
3837	1.00	4.00	0.80	0.94	0.83	0.03
3838	1.00	5.00	1.00	0.95	0.83	0.17
$\sum$	5.00			$\max S_n(x_i) - F(x_i) $		0.17
$\bar{x}$	3637.60					
s	211.68					

Ya que $D_{n,\alpha} = D_{5,0.05} = 0.56327 > 0.17 = \max |F(x_i) - S_n(x_i)|$ entonces se acepta h_0

Ejemplo KOLMOGÓROV-SMIRNOV

x_i	f_i	F_i	$S_n(x_i) = H_i$	$z_i = \frac{(x_i - \bar{x})}{s}$	$F(x_i) = P(z \leq z_i)$	$ F(x_i) - S_n(x_i) $
3334	1.00	1.00	0.20	-1.43	0.08	0.12
3554	1.00	2.00	0.40	-0.39	0.35	0.05
3625	1.00	3.00	0.60	-0.06	0.48	0.12
3837	1.00	4.00	0.80	0.94	0.83	0.03
3838	1.00	5.00	1.00	0.95	0.83	0.17
$\sum$	5.00			$\max S_n(x_i) - F(x_i) $		0.17
$\bar{x}$	3637.60					
s	211.68					

Ya que $D_{n,\alpha} = D_{5,0.05} = 0.56327 > 0.17 = \max |F(x_i) - S_n(x_i)|$ entonces se acepta h_0

Sumario

- Pruebas de normalidad
 - ANDERSON-DARLING
 - RYAN-JOINER
 - SHAPIRO-WILK
 - KOLMOGÓROV-SMIRNOV
- Perspectiva
 - Probar si una distribución se distribuye normalmente.
 - Realizar investigación con la prueba de normalidad: ANDERSON-DARLING, RYAN-JOINER, SHAPIRO-WILK Y KOLMOGÓROV-SMIRNOV.

Lecturas complementarias I



Rufino Moya C.

Probabilidad e Inferencia Estadística.

2da. Edición, 1990.



Miguel A. Gómez Villegas

Inferencia Estadística

2da. Edición, 2005.



Hernando G. C. Alvaro A. P. Ramiro C. Q.

estadística no paramétrica

3ra. Edición, 2006